

关于微内核的对话

不知怎么的，最近“微内核 vs 宏内核”又成了热门话题。这场争论从 1992 年开始……

FLAMEWAR

- In 1992, I said microkernels were better than monolithic designs
- Big flamewar with Linus Torvalds ensues
- 24 years later I still get lots of mail about this
- **Lesson: The Internet is like an elephant; it never forgets**



前言

说实话我很久没有关心操作系统了，因为通常所谓的“操作系统”在我心里不过是一个 C 语言的运行时系统（run-time system），就像 JVM 是 Java 的运行时系统一样。由于 C 语言的设计缺陷，这些系统引入了各种无需有的概念（进程，线程，虚拟内存……），以及它们带来的复杂性和开销。

微内核与宏内核之争当然也包括在内，在我看来这些都是无需有的概念和争论。操作系统相关的领域有很多的“宗教斗争”，比如“Linux vs Windows”，“自由软件 vs 不自由软件”，“RISC vs CISC”，甚至“VIM vs Emacs”……人们为了证明自己用的系统或者工具是世界上“最好”的，吵得昏天黑地。遇到有人指出自己用的工具的缺点，随时可能拿枪毙了对方。这些被叫做“flame war”。

我曾经是某些宗教斗争中活跃的一员，不知道这事的人可以去查一下我的历史。等你经历了很多才发现，原来这些宗教情绪和斗争都是那么幼稚无知。

这种“技术宗教情绪”往往显示出参与者心理地位的低下。因为他们缺乏自信，所以他们的心理需要靠山。这个靠山可能是某种操作系统（比如 Linux），某种编程语言（比如 C++），或者某种工具（比如 VIM）。这些人以自己能熟练使用这些工具为豪，居高临下，看不起“异教徒”。

具有技术宗教情绪的人看似是为了“技术”，“理想”，而其实跟那些以为开着豪车，穿着名牌就是“上流社会”的人是一样低级的，因为他们依靠于这些物品，所以他们的地位在这些物品之下。

一个人需要彻底的把这些东西看成是“东西”，不带有任何崇拜或者鄙视的情绪，他的心理才算是成熟了。

在我的理念里，一个操作系统本应该大概是[这个样子](#)。简单得很，根本不存在那么多问题。我可以利用这些思想来看透现有操作系统的绝大部分思想，管它是微内核还是宏内核。我可以把现有的操作系统看成是这个系统的“退化版”。

操作系统是一个死知识横行的领域。很多人发现操作系统课难学，难理解。里面有些内容，比如各种同步机制，很多人上完课毕了业，工作很多年以后都还弄不明白是怎么回事，它们为什么在那里。类似的东西包括虚拟内存，进程与线程的区别，等等。

经过了很多的经验和思考，加上其他领域给我的启发，我终于明白了。原来很多这些概念都是无须有的，死掉的知识。

操作系统课程里面的概念经常是这样形成的：

1. 很久以前，有人为了解决了一个特定的问题，提出了一个概念（比如 semaphore）。这个概念本来只有一个用途，就是解决他遇到的那个特定的问题。
2. 因为这人太有名，这概念就被写进了教科书里。有时候连他当时的具体实现细节都给写进去了。比如 semaphore 的两个操作被叫做 P 和 V，连这两个名字都给作为“典故”写进去了。
3. 教授们照本宣科，吹毛求疵，要你用这概念解决很多其它问题。很多根本就是人为造出来的变态问题，现实中遇不到的，或者是一些不该用这个概念解决的问题。

这就是为什么操作系统课学起来那么难——很多都是没道理的难。

再加上 Unix 系统里面一堆设计恶劣，无法有效组合使用的工具软件，操作系统就在学生心中产生了威慑力。死记硬背，喜欢折腾，喜欢发现奇技淫巧的人，在这个领域里茁壮成长。逐渐的，他们产生了莫名的自信。他们并不理解里面的很多概念是怎么来的，只是记住了它们，他们写的代码很难看懂。然后他们开始从心理上打压那些记不住这些概念，看不懂他们代码的人。

久而久之，这些人就成为了大家所崇拜的“神”。

跟有些人聊操作系统是件闹心的事，因为我往往会抛弃一些术语和概念，从零开始讨论。我试图从“计算本质”的出发点来理解这类事物，理解它们的起因，发展，现状和可能的改进。我所关心的往往是“这个事物应该是什么样子”，“它还可以是什么（也许更好的）样子”，而不只是“它现在是什么样子”。不明白我的这一特性，又自恃懂点东西的人，往往会误以为我连基本的术语都不明白。于是天就这样被他们聊死了。

幸运的是我有几个聊得来的朋友，他们不会那么教条主义。于是今天我跟一个朋友在微信上聊起了“微内核 vs 宏内核”这件事。其实这个问题在我脑子里已经比较清楚了，可是通过这些对话，我学到了新的东西。这些东西是我们在对话之前可能都没有完全理解的，也许很多其他人也没理解。所以我觉得可以把这些有价值的对话记录下来。

我不想从头解释这个事，因为你可以从网络上找到“微内核”和“宏内核”的设计原理。我想展示在这里的只是我们的对话，里面有对也有错，翻来覆去的思想斗争。对话是一个很有意思的东西，我觉得比平铺直叙的文章还要有效一些。

对话

好了，现在开始。对话人物“WY”是我，“LD”是我的一个朋友。

（8月19日，开始）

WY：好多年没折腾 OS，现在再折腾应该有新的发现。这篇 [paper](#) 说 Minix 3 比 Linux 要慢 510%。

WY：通常的定义，说微内核只需要 send 和 receive 两个系统调用。你不觉得有问题吗？其实函数调用的本质就是 send（参数）和 receive（返回值），但只有这两个系统调用，这种做法是过度的复用（multiplex）。

（下载 Minix 3 源代码看了一会儿。上网搜索关于微内核的资料……）

LD：是。

LD：一个外设产生了中断，中断管理进程接收到中断，发一个消息给相应的设备驱动进程，这个进程处理中断请求，如果设备驱动有 bug，挂了，也不会干扰 OS。这就是微内核逻辑。

WY：微内核似乎一直没解决性能问题。后面的 L4, QNX... 把 sever 隔离在不同的地址空间似乎是个最大的问题。

LD：导致通讯成本特别大。本来传递个地址就可以的事。现在要整个复制过去。

WY：地址空间不应该分开。或者也许可以在 MMU 上面做文章，传递时把那片内存给 map 过去。这样上下文切换又是一个开销……函数调用被搞的这么麻烦，微内核似乎确实是不行。对了，微内核服务调用时会产生进程切换吗？

LD：会，按照微内核的定义，每一个基本单元都是一个进程。

WY：完蛋了。

LD：内存管理是一个进程，IO 管理是一个进程，每个设备驱动是一个进程，中断管理是一个进程。

WY：进程切换的开销……

LD：为了降低进程间通信开销，所以定义了 L4。我也不太懂这个有啥用。

WY：改善的是通信开销，但仍然有进程切换开销。我刚看了一下 L4，它是从寄存器传值，但是进程切换会把寄存器都放到内存吧。

LD：对呀，所以 L4 意义似乎不大。

LD：带“微”的除了微软和微信，没一个成功的。

LD：最近流行的所谓微服务。

WY：驱动的 bug 应该有其他办法。

LD：现在的 OS 的问题，就是内核微小的错误，都是让整个系统挂掉。这和我们写软件应该用多进程还是多线程，同样的问题。

WY：应该从硬件底层彻底抛弃现在的进程切换方式。保存的上下文太多。

LD：现在 OS 不是分成 user 和 kernel 保护级别么。我觉得再增加一个两个保护级别，专门针对设备驱动程序似乎是更好的选择。

WY：我以前设想一个办法可以完全不需要保护级别，而且不需要虚拟内存。

LD：怎么办？编译器静态分析搞定？Rust？

WY：完全使用实地址，但是代码无法访问对象外面的内存。

LD：靠编译器保证？

WY：不需要多先进的编译器。语言里面没有指针这东西就行，这样你没法访问不是给你的对象。嗯，需要抛弃 C 语言……

LD：Rust！

WY：还用不着 Rust。其实 JVM 早就那样了。只不过通常不认为 JVM 是一个操作系统，但操作系统完全可以做成那样。

LD：所谓对象，就是每次地址访问，除了地址还有一个 size？超过 size 不允许？还是编译器确保一定不会超过 size？

WY: 你在 Java 或者其它高级语言比如 Python... 都没法访问对象外面的内存啊。只有 C 可以, 因为 C 有指针, 可以随便指到哪。

LD: 是的。C 这种方式, 就是天天在没有护栏的桥上走来走去。除了越界访问, 还有一个问题, 就是多个 task 同时改一块内存。

WY: 然后为了防止越界, 有了“进程”, “虚拟地址”这种概念。

LD: 虚拟地址, 还是为了用虚拟内存。

WY: 虚拟地址, 虚拟内存就是为了隔离。每个进程都以为地址从0开始, 然后本来很容易的函数调用被隔离开了。如果改变了这个, 微内核就真的可以很快了。实际上内核就不存在了..... 哦, 还是有。就只剩下调度器, 内存管理。

IPC 没了, 被函数调用所取代。

LD: 换个思路。其实 OS 最容易出问题的是硬件驱动, 所以尽量让硬件标准化, 别每个硬件都搞一套自己的驱动。让一套驱动支持多种硬件, 问题就解决了。比如 usb 驱动。完全可以做到一类硬件都用一个设备驱动。

WY: 我还是觉得驱动程序 bug 其实可以不导致当机。用内核线程行不行? 共享地址空间, 但是异步执行。

LD: Linux 似乎就是这样。tasklet, 可以被调度的。

WY: 所以驱动程序要是当掉, 可以不死对吗? 我回去查一下。

LD: 看啥错误了。不小心修改了其它模块的内存就完蛋了。其它错误最多硬件本身不能用了。

WY: 所以就是为什么你说再多一个保护级别。

LD: 嗯, 别碰了内核关键的代码。但是驱动之间还是可以互相干扰的。

WY: 是个不错的折中方案。所以微内核解决了一个不是那么关键的问题。

LD: 是的。这个问题不重要。哦, 对了, Windows 是微内核的。好像从 2000 开始。

WY: 只是号称吧。Mac OS X 不是号称 Mach 微内核加 BSD 吗?

LD: 对。MacOS 也是微内核。

WY: 那他们怎么解决的性能问题呢?

LD: 不知道。Windows 蓝屏可不少, 显然没做到完全隔离。至于 Mac, 不清楚为啥那么稳定。

WY: 根据我们之前的讨论, Mac 微内核可能是假的。Mac 稳定是因为它的 driver 就没几个吧, 硬件都是固定选好的。

LD: 嗯, 也是稳定的主要原因。

WY: 这个英明了..... 而且看来微内核在集群方面也没什么用处。

LD: 集群, 每个计算机是一个 node。挂了也不怕。

(8 月 20 日继续讨论)

WY: 我发现这个 [paper](#).....

WY: 这东西叫 L4Linux, 就是 Linux 跑在 L4 微内核上。比起纯 Linux, 开销只有 5%

WY: 代码在这里: <http://os.inf.tu-dresden.de/L4/LinuxOnL4>

WY: L4 的做法是 1) 小参数用寄存器传递, 不切换某些寄存器。2) 大型参数把内存映射到接收进程, 跟我之前设想的一样。这样避免了拷贝。然后采用了“direct process switch”, “lazy scheduling”降低了调度开销。现代处理器的 tagged TLB 之类也大大降低了进程切换开销。

L3 therefore uses a new method based on temporary mapping: the kernel determines the target region of the destination address space, maps it temporarily into a *communication window* in the source address space, and then copies the message directly from the sender's user space into its communication window. Due to aliasing the message appears at the right place in the receiver's address space.



Figure 4: *Direct Message Copy*

WY: 上图是 direct message copy。先把接收进程的地址映射到发送进程的地址空间, 然后发送进程往里拷贝。所以其实仍然有一次拷贝, 并不像我理想的 OS 那样直接就能传递对象引用, 完全不用拷贝。Pass-by-value vs pass-by-reference。但这比起 Linux 似乎开销是一样的。

LD: 微内核好处真的很大么?

WY: 好处就是微内核的好处, 隔离。可能看各人需求了。一个 99.99% 可靠的系统和一个 99.999999% 可靠的系统的差别?

WY: 不过似乎高可靠需求都去用 vxworks 之类的了

(上网查询 vxworks.....)

WY : 原来 vxworks 也是微内核。

WY : 5% 的开销还可以接受..... 进程切换开销貌似没有提, 用的地址映射方法。

LD : cross address space

WY : 刚买了个 tplink 路由器, 里面跑的 vxworks。

LD : tplink 不是 Linux ?

WY : 新的 tplink AC1900, 改成了 vxworks。Airport Extreme 也是 vxworks。

LD : why ?

WY : 实时, 可靠性高吧。

LD : 可靠性应该是最高的之一。卫星、武器都用。

WY : 波音 787 也用这个, 各种火星车..... 貌似还是说明一些问题。

WY : 还有个 [GreenHills Integrity DO-178B](#) 实时操作系统。F35 用的。

WY : Much of the F-35's software is written in C and C++ because of programmer availability; Ada83 code also is reused from the F-22. The Integrity DO-178B real-time operating system (RTOS) from Green Hills Software runs on COTS Freescale PowerPC processors.

WY : Freescale PowerPC...

LD : 我们的一个 mcu 就是 Freescale 的 PowerPC

LD : 有个叫“rtems”的 os, 我一直很关注。

WY : 摘自 Integrity DO-178B RTOS :

Safe and secure by design

- RTOS designed for use in reliable, mission critical, safety critical and secure (MILS & MLS) applications
- Based on modern microkernel RTOS design
- Fast, deterministic behavior with absolute minimum interrupt latencies

WY : Integrity 也是微内核。看来微内核是可靠一些, 属于在 C 语言框架下的一个不错的折中方案。

.....

(如果你有什么不同意见, 欢迎联系我。如果觉得有帮助, 可以考虑[付费](#))