怎样写一个解释器

写一个解释器,通常是设计和实现程序语言的第一步。解释器是简单却又深奥的东西,以至于好多人都不会写,所以 我决定写一篇这方面的入门读物。

虽然我试图从最基本的原理讲起,尽量不依赖于其它知识,但这并不是一本编程入门教材。我假设你已经理解 Scheme 语言,以及基本的编程技巧(比如递归)。如果你完全不了解这些,那我建议你读一下 <u>SICP</u> 的第一,二章,或者 <u>HtDP</u> 的前几章,习题可以不做。注意不要读太多书,否则你就回不来了;-)当然你也可以直接读这篇文章,有不懂的地方再去查资料。

实现语言容易犯的一个错误,就是一开头就试图去实现很复杂的语言(比如 JavaScript 或者 Python)。这样你很快就会因为这些语言的复杂性,以及各种历史遗留的设计问题而受到挫折,最后不了了之。学习实现语言,最好是从最简单,最干净的语言开始,迅速写出一个可用的解释器。之后再逐步往里面添加特性,同时保持正确。这样你才能有条不紊地构造出复杂的解释器。

因为这个原因,这篇文章只针对一个很简单的语言,名叫"R2"。它可以作为一个简单的计算器用,还具有变量定义,函数定义和调用等功能。

我们的工具: Racket

本文的解释器是用 Scheme 语言实现的。Scheme 有很多的"实现",这里我用的实现叫做 Racket,它可以在这里免费下载。为了让程序简洁,我用了一点点 Racket 的模式匹配(pattern matching)功能。我对 Scheme 的实现没有特别的偏好,但 Racket 方便易用,适合教学。如果你用其它的 Scheme 实现,可能得自己做一些调整。

Racket 具有宏(macro),所以它其实可以变成很多种语言。如果你之前用过 DrRacket,那它的"语言设置"可能被你改成了 R5RS 之类的。所以如果下面的程序不能运行,你可能需要检查一下 DrRacket 的"语言设置",把 Language 设置成"Racket"。



Racket 允许使用方括号而不只是圆括号,所以你可以写这样的代码:

(let ([x 1] [y 2]) (+ x y))

方括号跟圆括号可以互换,唯一的要求是方括号必须和方括号匹配。通常我喜欢用方括号来表示"无动作"的数据(比如上面的 [x 1], [y 2]) ,这样可以跟函数调用和其它具有"动作"的代码,产生"视觉差"。这对于代码的可读性是一个改善,因为到处都是圆括号的话,确实有点太单调,容易打瞌睡。

另外,Racket 程序的最上面都需要加上像 #lang racket 这样的语言选择标记,这样 Racket 才可以知道你想用哪个语言变种。

解释器是什么

准备工作就到这里。现在我来谈一下,解释器到底是什么。说白了,解释器跟计算器差不多。解释器是一个函数,你输入一个"表达式",它就输出一个"值",像这样:



比如,你输入表达式'(+ 1 2),它就输出值,整数3。表达式是一种"表象"或者"符号",而值却更加接近"本质"或者"意义"。我们"解释"了符号,得到它的意义,这也许就是为什么它叫做"解释器"。

需要注意的是,表达式是一个数据结构,而不是一个字符串。我们用一种叫"S表达式"(S-expression)的结构来存储表达式。比如表达式 '(+ 1 2) 其实是一个链表(list),它里面的内容是三个符号(symbol):+, 1 和 2,而不是字符串"(+ 1 2)"。

从 S 表达式这样的"结构化数据"里提取信息,方便又可靠,而从字符串里提取信息,麻烦而且容易出错。Scheme (Lisp) 语言里面大量使用结构化数据,少用字符串,这是 Lisp 系统比 Unix 系统先进的地方之一。

从计算理论的角度讲,每个程序都是一台机器的"描述",而解释器就是在"模拟"这台机器的运转,也就是在进行"计算"。所以从某种意义上讲,解释器就是计算的本质。当然,不同的解释器就会带来不同的计算。

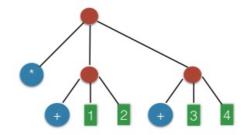
CPU 也是一个解释器,它专门解释执行机器语言。如果你深刻理解了解释器,就可以从本质上看出各种 CPU 的设计为什么是那个样子,它们有什么优缺点,而不只是被动的作为它们的使用者。

抽象语法树 (Abstract Syntax Tree)

用S表达式所表示的代码,本质上是一种叫做"树"(tree)的数据结构。更具体一点,这叫做"抽象语法树"(Abstract Syntax Tree,简称 AST)。下文为了简洁,我们省略掉"抽象"两个字,就叫它"语法树"。

跟普通的树结构一样,语法树里的节点,要么是一个"叶节点",要么是一颗"子树"。叶节点是不能再细分的"原子",比如数字,字符串,操作符,变量名。而子树是可以再细分的"结构",比如算术表达式,函数定义,函数调用,等等。

举个简单的例子,表达式 '(* (+ 1 2) (+ 3 4)),就对应如下的语法树结构:



其中,*,两个+,1,2,3,4都是叶节点,而那三个红色节点,都表示子树结构:'(+ 1 2),'(+ 3 4),'(* (+ 1 2) (+ 3 4))。

树遍历算法

在基础的数据结构课程里,我们都学过二叉树的遍历操作,也就是所谓先序遍历,中序遍历和后序遍历。语法树跟二 叉树,其实没有很大区别,所以你也可以在它上面进行遍历。解释器的算法,就是在语法树上的一种遍历操作。由于 这个渊源关系,我们先来做一个遍历二叉树的练习。做好了之后,我们就可以把这段代码扩展成一个解释器。

这个练习是这样:写出一个函数,名叫tree-sum,它对二叉树进行"求和",把所有节点里的数加在一起,返回它们的和。举个例子,(tree-sum '((1 2) (3 4))),执行后应该返回 10。注意:这是一颗二叉树,所以不会含有长度超过 2 的子树,你不需要考虑像 ((1 2) (3 4 5)) 这类情况。需要考虑的例子是像这样:(1 2),(1 (2 3)), ((1 2) 3) ((1 2) (3 4)),……

(为了达到最好的学习效果,你最好试一下写出这个函数再继续往下看。)

好了,希望你得到了跟我差不多的结果。我的代码是这个样子:

#lang racket

你可以通过以下的例子来测试它的正确性:

```
(tree-sum '(1 2))
;; => 3
(tree-sum '(1 (2 3)))
;; => 6
```

```
(tree-sum '((1 2) 3));; => 6
(tree-sum '((1 2) (3 4)));; => 10
```

(完整的代码和示例,可以在这里下载。)

这个算法很简单,我们可以把它用文字描述如下:

- 1. 如果输入 exp 是一个数,那就返回这个数。
- 2. 否则如果 exp 是像 (,e1 ,e2) 这样的子树,那么分别对 e1 和 e2 递归调用 tree-sum,进行求和,得到 v1 和 v2,然后返回 v1 + v2 的和。

你自己写出来的代码,也许用了 if 或者 cond 语句来进行分支,而我的代码里面使用的是 Racket 的模式匹配 (match)。这个例子用 if 或者 cond 其实也可以,但我之后要把这代码扩展成一个解释器,所以提前使用了 match。这样跟后面的代码对比的时候,就更容易看出规律来。接下来,我就简单讲一下这个 match 表达式的工作原理。

模式匹配

现在不得不插入一点 Racket 的技术细节,如果你已经学会使用 Racket 的模式匹配,可以跳过这一节。你也可以通过阅读 Racket 模式匹配的<u>文档</u>来代替这一节。但我建议你不要读太多文档,因为我接下去只用到很少的模式匹配功能,我把它们都解释如下。

模式匹配的形式一般是这样:

```
(match x
[模式 结果]
[模式 结果]
...
```

它先对 x 求值,然后根据值的结构来进行分支。每个分支由两部分组成,左边是一个模式,右边是一个结果。整个 match 语句的语义是这样:从上到下依次考虑,找到第一个可以匹配 x 的值的模式,返回它右边的结果。左边的模式 在匹配之后,可能会绑定一些变量,这些变量可以在右边的表达式里使用。

模式匹配是一种分支语句,它在逻辑上就是 Scheme(Lisp)的 cond 表达式,或者 Java 的嵌套条件语句 if ... else if ... else ...。然而跟条件语句里的"条件"不同,每条 match 语句左边的模式,可以准确而形象地描述数据结构的形状,而且可以在匹配的同时,对结构里的成员进行"绑定"。这样我们可以在右边方便的访问结构成员,而不需要使用访问函数(accessor)或者 foo.x 这样的属性语法(attribute)。而且模式可以有嵌套的子结构,所以它能够一次性的表示复杂的数据结构。

举个实在点的例子。我的代码里用了这样一个 match 表达式:

第二行里面的 ' (,e1 ,e2) 是一个模式 (pattern) ,它被用来匹配 exp 的值。如果 exp 是 ' (1 2),那么它与' (,e1 ,e2)匹配的时候,就会把 e1 绑定到 '1,把 e2 绑定到 '2。这是因为它们结构相同:

```
`(,e1 ,e2)
'( 1 2)
```

说白了,模式就是一个可以含有"名字"(像 e1 和 e2)的结构,像 '(,e1 ,e2)。我们拿这个带有名字的结构,去匹配实际数据,像 '(1 2)。当它们一一对应之后,这些名字就被绑定到数据里对应位置的值。

第一行的"模式"比较特殊,(? number? x) 表示的,其实是一个普通的条件判断,相当于 (number? exp),如果这个条件成立,那么它把 exp 的值绑定到 x,这样右边就可以用 x 来指代 exp。对于无法细分的结构(比如数字,布尔值),你只能用这种方式来"匹配"。看起来有点奇怪,不过习惯了就好了。

模式匹配对解释器和编译器的书写相当有用,因为程序的语法树往往具有嵌套的结构。不用模式匹配的话,往往要写冗长,复杂,不直观的代码,才能描述出期望的结构。而且由于结构的嵌套比较深,很容易漏掉边界情况,造成错误。模式匹配可以直观的描述期望的结构,避免漏掉边界情况,而且可以方便的访问结构成员。

由于这个原因,很多源于 ML 的语言(比如 OCaml,Haskell)都有模式匹配的功能。因为 ML(Meta-Language)原来设计的用途,就是用来实现程序语言的。Racket 的模式匹配也是部分受了 ML 的启发,实际上它们的原理是一模一样的。

好了,树遍历的练习就做到这里。然而这跟解释器有什么关系呢?下面我们只把它改一下,就可以得到一个简单的解 释器。

一个计算器

计算器也是一种解释器,只不过它只能处理算术表达式。我们的下一个目标,就是写出一个计算器。如果你给它'(* (+ 1 2) (+ 3 4)),它就输出 21。可不要小看这个计算器,稍后我们把它稍加改造,就可以得到一个更多功能的解释器。

上面的代码里,我们利用递归遍历,对树里的数字求和。那段代码里,其实已经隐藏了一个解释器的框架。你观察一下,一个算术表达式 '(* (+ 1 2) (+ 3 4)),跟二叉树 '((1 2) (3 4)) 有什么不同?发现没有,这个算术表达式比起二叉树,只不过在每个子树结构里多出了一个操作符:一个 * 和两个 + 。它不再是一棵二叉树,而是一种更通用的树结构。

这点区别,也就带来了二叉树求和与解释器算法的区别。对二叉树进行求和的时候,在每个子树节点,我们都做加法。而对表达式进行解释的时候,在每一个子树节点,我们不一定进行加法。根据子树的"操作符"不同,我们可能会选择加,减,乘,除四种操作。

好了,下面就是这个计算器的代码。它接受一个表达式,输出一个数字作为结果。

```
#lang racket
                                      ; 声明用 Racket 语言
(define calc
 (lambda (exp)
                                      ; 分支匹配:表达式的两种情况
   (match exp
     [(? number? x) x]
                                     ; 是数字,直接返回
                                     ; 匹配提取操作符op和两个操作数e1,e2
     [`(,op ,e1 ,e2)
      (let ([v1 (calc e1)]
                                      ; 递归调用 calc 自己,得到 e1 的值
          [v2 (calc e2)])
                                      ; 递归调用 calc 自己, 得到 e2 的值
                                     ;分支匹配:操作符 op 的 4 种情况
       (match op
         ['+ (+ v1 v2)]
                                      ; 如果是加号, 输出结果为 (+ v1 v2)
         ['- (- v1 v2)]
                                      ;如果是减号,乘号,除号,相似的处理
         ['* (* v1 v2)]
         ['/ (/ v1 v2)])))))
```

你可以得到如下的结果:

```
(calc '(+ 1 2))
;; => 3
(calc '(* 2 3))
;; => 6
(calc '(* (+ 1 2) (+ 3 4)))
;; => 21
```

(完整的代码和示例,可以在这里下载。)

跟之前的二叉树求和代码比较一下,你会发现它们惊人的相似,因为解释器本来就是一个树遍历算法。不过你发现它们有什么不同吗?它们的不同点在于:

- 1. 算术表达式的模式里面,多出了一个"操作符"(op)叶节点:(,op,e1,e2)
- 2. 对子树 e1 和 e2 分别求值之后,我们不是返回 (+ v1 v2),而是根据 op 的不同,返回不同的结果:

```
(match op

['+ (+ v1 v2)]

['- (- v1 v2)]

['* (* v1 v2)]

['/ (/ v1 v2)])
```

最后你发现,一个算术表达式的解释器,不过是一个稍加扩展的树遍历算法。

R2:一个很小的程序语言

实现了一个计算器,现在让我们过渡到一种更强大的语言。为了方便称呼,我给它起了一个萌萌哒名字,叫 R2。R2 比起之前的计算器,只多出四个元素,它们分别是:变量,函数,绑定,调用。再加上之前介绍的算术操作,我们就得到一个很简单的程序语言,它只有5种不同的构造。用 Scheme 的语法,这5种构造看起来就像这样:

变量:x

函数: (lambda (x) e)绑定: (let ([x e1]) e2)

• 调用:(e1 e2)

• 算术: (• e2 e2)

(其中, • 是一个算术操作符,可以选择 +, -, *, / 其中之一)

一般程序语言还有很多其它构造,可是一开头就试图去实现所有那些,只会让人糊涂。最好是把这少数几个东西搞清楚,确保它们正确之后,才慢慢加入其它元素。

这些构造的语义,跟 Scheme 里面的同名构造几乎一模一样。如果你不清楚什么是"绑定",那你可以把它看成是普通语言里的"变量声明"。

需要注意的是,跟一般语言不同,我们的函数只接受一个参数。这不是一个严重的限制,因为在我们的语言里,函数可以被作为值传递,也就是所谓"first-class function"。所以你可以用嵌套的函数定义来表示有两个以上参数的函数。

举个例子,(lambda(x)(lambda(y)(+ x y)))是个嵌套的函数定义,它也可以被看成是有两个参数(x 和 y)的函数,这个函数返回 x 和 y 的和。当这样的函数被调用的时候,需要两层调用,就像这样:

这种做法在PL术语里面,叫做咖喱(currying)。看起来啰嗦,但这样我们的解释器可以很简单。等我们理解了基本的解释器,再实现真正的多参数函数也不迟。

另外,我们的绑定语法(let ([x e1]) e2),比起 Scheme 的绑定也有一些局限。我们的 let 只能绑定一个变量,而 Scheme 可以绑定多个,像这样 (let ([x 1] [y 2]) (+ x y))。这也不是一个严重的限制,因为我们可以啰嗦一点,用嵌套的 let 绑定:

```
(let ([x 1])
  (let ([y 2])
   (+ x y)))
```

R2 的解释器

下面是我们今天要完成的解释器,它可以运行一个 R2 程序。你可以先留意一下各部分的注释。

#lang racket

```
;;; 以下三个定义 env0, ext-env, lookup 是对环境 (environment) 的基本操作:
;; 空环境
(define env0 '())
;; 扩展。对环境 env 进行扩展, 把 x 映射到 v, 得到一个新的环境
(define ext-env
 (lambda (x v env)
   (cons `(,x . ,v) env)))
;; 查找。在环境中 env 中查找 x 的值。如果没找到就返回 #f
(define lookup
 (lambda (x env)
   (let ([p (assq x env)])
     (cond
      [(not p) #f]
      [else (cdr p)]))))
;; 闭包的数据结构定义,包含一个函数定义 f 和它定义时所在的环境
(struct Closure (f env))
;; 解释器的递归定义(接受两个参数,表达式 exp 和环境 env)
;; 共 5 种情况(变量,函数,绑定,调用,数字,算术表达式)
(define interp
 (lambda (exp env)
                                                 ;对exp进行模式匹配
   (match exp
     [(? symbol? x)
                                                 ; 变量
      (let ([v (lookup x env)])
        (cond
        [(not v)
         (error "undefined variable" x)]
        [else v]))]
```

```
[(? number? x) x]
                                                     ;数字
     [`(lambda (,x) ,e)
                                                     ;函数
      (Closure exp env)]
     [`(let ([,x ,e1]) ,e2)
                                                     ; 绑定
      (let ([v1 (interp e1 env)])
        (interp e2 (ext-env x v1 env)))]
     [`(,e1 ,e2)
                                                     ;调用
      (let ([v1 (interp e1 env)]
            [v2 (interp e2 env)])
        (match v1
          [(Closure `(lambda (,x) ,e) env-save)
           (interp e (ext-env x v2 env-save))]))]
     [`(,op ,e1 ,e2)
                                                     ; 算术表达式
      (let ([v1 (interp e1 env)]
            [v2 (interp e2 env)])
        (match op
          ['+ (+ v1 v2)]
          ['- (- v1 v2)]
          ['* (* v1 v2)]
          ['/ (/ v1 v2)])))))
;; 解释器的"用户界面"函数。它把 interp 包装起来,掩盖第二个参数,初始值为 env0
(define r2
 (lambda (exp)
    (interp exp env0)))
这里有一些测试例子:
(r2 '(+ 1 2))
;; => 3
(r2 '(* 2 3))
;; => 6
(r2 '(* 2 (+ 3 4)))
;; => 14
(r2 '(* (+ 1 2) (+ 3 4)))
;; => 21
(r2 '((lambda (x) (* 2 x)) 3))
;; => 6
(r2
'(let ([x 2])
   (let ([f (lambda (y) (* x y))])
    (f 3))))
;; => 6
'(let ([x 2])
   (let ([f (lambda (y) (* x y))])
    (let ([x 4])
      (f 3)))))
;; => 6
 (完整的代码和示例,可以在这里下载。)
```

在接下来的几节,我们来仔细看看这个解释器的各个部分。

对基本算术操作的解释

算术操作一般都是程序里最基本的构造,它们不能再被细分为多个步骤,所以我们先来看看对算术操作的处理。以下就是 R2 解释器处理算术的部分,它是 interp 的最后一个分支。

```
(match exp
... ...
[`(,op ,e1 ,e2)
(let ([v1 (interp e1 env)] ; 递归调用 interp 自己,得到 e1 的值
[v2 (interp e2 env)]) ; 递归调用 interp 自己,得到 e2 的值
(match op ; 分支:处理操作符 op 的 4 种情况
['+ (+ v1 v2)] ; 如果是加号,输出结果为 (+ v1 v2)
['- (- v1 v2)] ; 如果是减号,乘号,除号,相似的处理
['* (* v1 v2)]
```

```
['/ (/ v1 v2)]))])
```

你可以看到它几乎跟刚才写的计算器一模一样,不过现在 interp 的调用多了一个参数 env 而已。这个 env 是所谓"环境",我们下面很快就讲。

对数字的解释

对数字的解释很简单,把它们原封不动返回就可以了。

```
[(? number? x) x]
```

变量和函数

变量和函数是解释器里最麻烦的部分,所以我们来仔细看看。

变量(variable)的产生,是数学史上的最大突破之一。因为变量可以被绑定到不同的值,从而使函数的实现成为可能。比如数学函数 f(x)=x*2,其中 x 是一个变量,它把输入的值传递到函数体 x*2 里面。如果没有变量,函数就不可能实现。

对变量最基本的操作,是对它的"绑定"(binding)和"取值"(evaluate)。什么是绑定呢?拿上面的函数 f(x) 作为例子。当我们调用 f(1) 时,函数体里面的 x 等于 x 1,所以 x 2 的值是 x 2,而当我们调用 x 2 的值是 x 4。这里,两次对 x 6 的调用,分别对 x 进行了两次绑定。第一次 x 被绑定到了 x 2,被绑定到了 x 2。

你可以把"绑定"理解成这样一个动作,就像当你把插头插进电源插座的那一瞬间。插头的插脚就是 f(x) 里面的那个 x,而 x * 2 里面的 x,则是电线的另外一端。所以当你把插头插进插座,电流就通过这根电线到达另外一端。如果电线导电性能良好,两头的电压应该相等。

环境

我们的解释器只能一步一步的做事情。比如,当它需要求 f(1) 的值的时候,它分成两步操作:

- 1. 把 x 绑定到 1, 这样函数体内才能看见这个绑定。
- 2. 进入 f 的函数体,对 x * 2 进行求值。

这就像一个人做出这两个动作:

- 1. 把插头插进插座。
- 2. 到电线的另外一头,测量它的电压,并且把结果乘以2。

在第一步和第二步之间,我们如何记住 x 的值呢?通过所谓"环境"!我们用环境记录变量的值,并且把它们传递到变量的"可见区域"。变量的可见区域,用术语说叫做"作用域"(scope)。

在我们的解释器里,用于处理环境的代码如下:

这里我们用一种最简单的数据结构,Scheme 的 association list,来表示环境。Association list 看起来像这个样子:((x . 1) (y . 2) (z . 5))。它是一个两元组(pair)的链表,左边的元素是 key,右边的元素是 value。写得直观一点就是:

```
((x . 1)
(y . 2)
(z . 5))
```

查表操作就是从头到尾搜索,如果左边的 key 是要找的变量,就返回整个 pair。简单吧?效率很低,但是足够完成我

们现在的任务。

ext-env 函数扩展一个环境。比如,如果原来的环境 env1 是 ((y . 2) (x . 1)) 那么 (ext-env x 3 env1),就会返回 ((x . 3) (y . 2) (x . 1))。也就是把 (x . 3) 加到 env1 的最前面去。

那我们什么时候需要扩展环境呢?当我们进行绑定的时候。绑定可能出现在函数调用时,也可能出现在 let 绑定时。我们选择的数据结构,使得环境自然而然的具有了作用域(scope)的特性。

环境其实是一个堆栈 (stack)。内层的绑定,会出现在环境的最上面,这就是在"压栈"。这样我们查找变量的时候,会优先找到最内层定义的变量。

举个例子:

```
(let ([x 1]) ; env='()。绑定x到1。
  (let ([y 2]) ; env='((x . 1))。绑定y到2。
    (let ([x 3]) ; env='((y . 2) (x . 1))。绑定x到3。
    (+ x y)))) ; env='((x . 3) (y . 2) (x . 1))。查找x,得到3;查找y,得到2。
;; => 5
```

这段代码会返回5。这是因为最内层的绑定,把 (x . 3) 放到了环境的最前面,这样查找 x 的时候,我们首先看到 (x . 3) ,然后就返回值3。之前放进去的 (x . 1) 仍然存在,但是我们先看到了最上面的那个(x . 3) ,所以它被忽略了。

这并不等于说 (x . 1) 就可以被改写或者丢弃,因为它仍然是有用的。你只需要看一个稍微不同的例子,就知道这是怎么回事:

```
(let ([x 1]) ; env='()。绑定x到1。
(+ (let ([x 2]) ; env='((x . 1))。绑定x到2。
x) ; env='((x . 2) (x . 1))。查找x,得到2。
x)) ; env='((x . 1))。查找x,得到1。
;; => 3 ; 两个不同的x的和,1+2等于3。
```

这个例子会返回3。它是第3行和第4行里面两个 x 的和。由于第3行的 x 处于内层 let 里面,那里的环境是 ((x . 2) (x . 1)),所以查找 x 的值得到2。第4行的 x 在内层 let 外面,但是在外层 let 里面,那里的环境是 ((x . 1)),所以查找 x 的值得到1。这很符合直觉,因为 x 总是找到最内层的定义。

值得注意的是,环境被扩展以后,形成了一个新的环境,而原来的环境并没有被改变。比如,上面的((y . 2) (x . 1))并没有删除或者修改,只不过是被"引用"到一个更大的列表里去了。

这样不对已有数据进行修改(mutation)的数据结构,叫做"函数式数据结构"。函数式数据结构只生成新的数据,而不改变或者删除老的。它可能引用老的结构,然而却不改变老的结构。这种"不修改"(immutable)的性质,在我们的解释器里是很重要的,因为当我们扩展一个环境,进入递归,返回之后,外层的代码必须仍然可以访问原来外层的环境。

当然,我们也可以用另外的,更高效的数据结构(比如平衡树,串接起来的哈希表)来表示环境。如果你学究一点,甚至可以用函数来表示环境。这里为了代码简单,我们选择了最笨,然而正确,容易理解的数据结构。

对变量的解释

了解了变量,函数和环境,我们来看看解释器对变量的"取值"操作,也就是 match 的第一种情况。

```
[(? symbol? x) (lookup x env)]
```

这就是在环境中,沿着从内向外的"作用域顺序",查找变量的值。

这里的 (? symbol? x) 是一种特殊的模式,它使用 Scheme 函数 symbol? 来判断输入是否是一个符号,如果是,就把它绑定到 x,然后你就可以在右边用 x 来指称这个输入。

对绑定的解释

现在我们来看看对 let 绑定的解释:

通过代码里的注释,你也许已经可以理解它在做什么。我们先对表达式 e1 求值,得到 v1。然后我们把 $(x \cdot v1)$ 扩充 到环境里,这样 $(let ([x e1]) \ldots)$ 内部都可以看到 x 的值。然后我们使用这个扩充后的环境,递归调用解释器本身,对 let 的主体 e2 求值。它的返回值就是这个 let 绑定的值。

Lexical Scoping 和 Dynamic Scoping

下面我们准备谈谈函数定义和调用。对函数的解释是一个微妙的问题,很容易弄错,这是由于函数体内也许会含有外层的变量,叫做"自由变量"。所以在分析函数的代码之前,我们来了解一下不同的"作用域"(scoping)规则。

我们举个例子来解释这个问题。下面这段代码,它的值应该是多少呢?

```
(let ([x 2])
  (let ([f (lambda (y) (* x y))])
      (let ([x 4])
      (f 3))))
```

在这里,f 函数体(lambda(y)(* x y)) 里的那个 x,就是一个"自由变量"。x 并不是这个函数的参数,也不是在这个函数里面定义的,所以我们必须到函数外面去找 x 的值。

我们的代码里面,有两个地方对 x 进行了绑定,一个等于2 ,一个等于4 ,那么 x 到底应该是指向哪一个绑定呢?这似乎无关痛痒,然而当我们调用 (f 3) 的时候,严重的问题来了。f 的函数体是 (f x y),我们知道 y 的值来自参数 f 可是 f 的值是多少呢?它应该是f 2,还是f 4呢?

在历史上,这段代码可能有两种不同的结果,这种区别一直延续到今天。如果你在 Scheme (Racket)里面写以上的代码,它的结果是6。

现在我们来看看,在 Emacs Lisp 里面输入等价的代码,得到什么结果。如果你不熟悉 Emacs Lisp 的用法,那你可以跟我做:把代码输入 Emacs 的那个叫 *scratch* 的 buffer。把光标放在代码最后,然后按 C-x C-e,这样 Emacs 会执行这段代码,然后在 minibuffer 里显示结果:

```
(let ((x 2))
  (let ((f (lambda (y) (* x y))))
       (let ((x 4))
            (funcall f 3))))
U:**- *scratch* All (5,0)
```

结果是12!如果你把代码最内层的 x 绑定修成其它的值,输出会随之改变。

奇怪吧?Scheme 和 Emacs Lisp,到底有什么不一样呢?实际上,这两种看似差不多的"Lisp 方言",采用了两种完全不同的作用域方式。Scheme 的方式叫做 lexical scoping (或者 static scoping),而 Emacs 的方式叫做 dynamic scoping。

那么哪一种方式更好呢?或者用哪一种都无所谓?答案是,dynamic scoping 是非常错误的做法。历史的教训告诉我们,它会带来许许多多莫名其妙的 bug,导致 dynamic scoping 的语言几乎完全没法用。这是为什么呢?

原因在于,像 (let ((x 4)) …) 这样的变量绑定,只应该影响它内部"看得见"的 x 的值。当我们看见 (let ((x 4)) (f 3)) 的时候,并没有在 let 的内部看见任何叫"x" 的变量,所以我们"直觉"的认为,(let ((x 4)) …) 对 x 的绑定,不应该引起 (f 3) 的结果变化。

然而对于 dynamic scoping,我们的直觉却是错误的。因为 f 的函数体里面有一个 x,虽然我们没有在 (f 3) 这个调用里面看见它,然而它却存在于 f 定义的地方。要知道,f 定义的地方也许隔着几百行代码,甚至在另外一个文件里面。而且调用函数的人凭什么应该知道, f 的定义里面有一个自由变量,它的名字叫做 x ? 所以 dynamic scoping 在设计学的角度来看,是一个反人类的设计:)

相反,lexical scoping 却是符合人们直觉的。虽然在 (let ((x 4)) (f 3)) 里面,我们把 x 绑定到了 4,然而 f 的函数体并不是在那里定义的,我们也没在那里看见任何 x,所以 f 的函数体里面的 x,仍然指向我们定义它的时候看得见的那个 x,也就是最上面的那个 (let ([x 2]) ...),它的值是 2。所以 (f 3) 的值应该等于 6,而不是12。

对函数的解释

为了实现 lexical scoping,我们必须把函数做成"闭包"(closure)。闭包是一种特殊的数据结构,它由两个元素组

成:函数的定义和当前的环境。我们把闭包定义为一个 Racket 的 struct 结构:

```
(struct Closure (f env))
```

有了这个数据结构,我们对(lambda(x)e)的解释就可以写成这样:

```
[`(lambda (,x) ,e)
 (Closure exp env)]
```

注意这里的 exp 就是 ``(lambda (,x),e)` 自己。

有意思的是,我们的解释器遇到(lambda(x)e),几乎没有做任何计算。它只是把这个函数包装了一下,把它与当前的环境一起,打包放到一个数据结构(Closure)里面。这个闭包结构,记录了我们在函数定义的位置"看得见"的那个环境。稍候在调用的时候,我们就能从这个闭包的环境里面,得到函数体内的自由变量的值。

对调用的解释

好了,我们终于到了最后的关头,函数调用。为了直观,我们把函数调用的代码拷贝如下:

```
[`(,e1 ,e2)
(let ([v1 (interp e1 env)] ; 计算函数 e1 的值
        [v2 (interp e2 env)]) ; 计算参数 e2 的值
(match v1
        [(Closure `(lambda (,x) ,e) env-save) ; 用模式匹配的方式取出闭包里的各个子结构
        (interp e (ext-env x v2 env-save))]))] ; 在闭包的环境env-save中把x绑定到v2,解释函数体
```

函数调用都是 (e1 e2) 这样的形式, e1 表示函数, e2 是它的参数。我们需要先分别求出函数 e1 和参数 e2 的值。

函数调用就像把一个电器的插头插进插座,使它开始运转。比如,当(lambda(x)(* x 2))被作用于 1 时,我们把 x 绑定到 1,然后解释它的函数体(* x 2)。但是这里有一个问题,函数体内的自由变量应该取什么值呢?从上面闭包的讨论,你已经知道了,自由变量的值,应该从闭包的环境查询。

操作数 e1 的值 v1 是一个闭包,它里面包含一个函数定义时保存的环境 env-save。我们把这个环境 env-save 取出来,那我们就可以查询它,得到函数体内自由变量的值。然而函数体内不仅有自由变量,还有对函数参数的使用,所以我们必须扩展这个 env-save 环境,把参数的值加进去。这就是为什么我们使用 (ext-env x v2 env-save),而不只是 env-save。

你可能会奇怪,那么解释器的环境 env 难道这里就不用了吗?是的。我们通过 env 来计算 e1 和 e2 的值,是因为 e1 和 e2 里面的变量,在"当前环境" (env) 里面看得见。可是函数体的定义,在当前环境下是看不见的。它的代码在别的地方,而那个地方看得见的环境,被我们存在闭包里了,它就是 env-save。所以我们把 v1 里面的闭包环境 env-save 取出来,用于计算函数体的值。

有意思的是,如果我们用 env,而不是env-save 来解释函数体,那我们的语言就变成了 dynamic scoping。现在来实验一下:你可以把 (interp e (ext-env x v2 env-save)) 里面的 env-save 改成 env,再试试我们之前讨论过的代码,它的输出就会变成 12。那就是我们之前讲过的,dynamic scoping 的结果。

你也许发现了,如果我们的语言是 dynamic scoping,那就没必要使用闭包了,因为我们根本不需要闭包里面保存的环境。这样一来,dynamic scoping 的解释器就可以写成这样:

注意到这个解释器的函数有多容易实现吗?它就是这个函数的表达式自己,原封不动。用函数的表达式本身来表示它的值,是很直接很简单的做法,也是大部分人一开头就会想到的。然而这样实现出来的语言,就不知不觉地采用了dynamic scoping。

这就是为什么很多早期的 Lisp 语言,比如 Emacs Lisp,都使用 dynamic scoping。这并不是因为它们的设计者在 dynamic scoping 和 lexical scoping 两者之中做出了选择,而是因为使用函数的表达式本身来作为它的值,是最直接,一般人都会首先想到的做法。

另外,在这里我们也看到环境用"函数式数据结构"表示的好处。闭包被调用时它的环境被扩展,但是这并不会影响原来的那个环境,我们得到的是一个新的环境。所以当函数调用返回之后,函数的参数绑定就自动"注销"了。

如果你用一个非函数式的数据结构,在绑定参数时不生成新的环境,而是对已有环境进行赋值,那么这个赋值操作就会永久性的改变原来环境的内容。所以你在函数返回之后必须删除参数的绑定。这样不但麻烦,而且在复杂的情况下很容易出错。

思考题:可能有些人看过 lambda calculus,这些人可能知道 (let ([x e1]) e2) 其实等价于一个函数调用:((lambda (x) e2) e1)。现在问题来了,我们在讨论函数和调用的时候,很深入的讨论了关于 lexical scoping和 dynamic scoping的差别。既然 let 绑定等价于一个函数定义和调用,为什么之前我们讨论对绑定的时候,没有讨论过 lexical scoping和 dynamic scoping的问题,也没有制造过闭包呢?

不足之处

现在你已经学会了如何写出一个简单的解释器,它可以处理一个相当强大的函数式语言。出于教学的考虑,这个解释器并没有考虑实用的需求,所以它并不能作为工业应用。在这里,我指出它的一些不足之处。

- 1. 缺少必要的语言构造。我们的语言里缺少好些实用语言必须的构造:递归,数组,赋值操作,字符串,自定义数据结构,……作为一篇基础性的读物,我不能把这些都加进来。如果你对这些有兴趣,可以看看其它书籍,或者等待我的后续作品。
- 2. 不合法代码的检测和报告。你也许发现了,这个解释器的 match 表达式,全都假定了输入都是合法的程序,它并没有检查不合法的情况。如果你给它一个不合法的程序,它不会马上报错,而是会真去算它,以至于导致奇怪的后果。一个实用的解释器,必须加入对代码格式进行全面检测,在运行之前就报告不合法的代码结构。
- 3. 低效率的数据结构。在 association list 里面查找变量,是线性的复杂度。当程序有很多变量的时候就有性能问题。一个实用的解释器,需要更高效的数据结构。这种数据结构不一定非得是函数式的。你也可以用非函数式的数据结构(比如哈希表),经过一定的改造,达到同样的性质,却具有更高的效率。 另外,你还可以把环境转化成一个数组。给环境里的每个变量分配一个下标(index),在这个数组里就可以找到它的值。如果你用数组表示环境,那么这个解释器就向编译器迈进了一步。
- 4. S 表达式的歧义问题。为了教学需要,我们的解释器直接使用 S 表达式来表达语法树,用模式匹配来进行分支遍历。在实际的语言里,这种方式会带来比较大的问题。因为 S 表达式是一种通用的数据结构,用它表示的东西,看起来都差不多的样子。一旦程序的语法构造多起来,直接对 S 表达式进行模式匹配,会造成歧义。

比如 (,op,e1,e2),你以为它只匹配二元算术操作,比如 (+12)。但它其实也可以匹配一个 let 绑定: (let ([x1]) (*x2))。这是因为它们顶层元素的数目是一样的。为了消除歧义,你得小心的安排模式的顺序,比如你必须把 (let([,x,e1]) ,e2) 的模式放在 (,op,e1,e2) 前面。所以最好的办法,是不要直接在 S 表达式上写解释器,而是先写一个"parser",这个 parser 把 S 表达式转换成 Racket 的 struct 结构。然后解释器再在 struct 上面进行分支匹配。这样解释器不用担心歧义问题,而且会带来效率的提升。

付费方式

如果你喜欢这篇文章,可以到这里付费购买。